

在线服务公司IT项目立项需求及技术规范书评审纪要

项目名称	在线营销服务中心 2025-2026 年智算资源服务采购框架项目				
申请单位	平台运维中心				
会议时间	2025 年 8 月 28	会议地点	线上评审	答辩人员	邹金柱
纪要时间	2025 年 8 月 29 日				
项目类型	○ 软件研发建设 ○ 软件建设 ○ 软件购买 ○ 购买授权 ○ 硬件采购、扩容改造 ○ 研发技术支撑服务 ○ 技术支撑服务 ○ 软件维护 ● 硬件维保、维修、租赁 ○ 机房租赁				
评审专家	业务： AI 能力中心：张士新、鲍子林、孟祥义、朱亚辉、吴洋洋、史津丞 云客服事业部：张荣勋、刘光旭 技术： 平台运维中心：白子玉、周洋、李超峰 安全： 平台运维中心：张明 财务： 财务部：毛以琦 供应链： 供应链管理部：王家辉 中台： 基础能力中心：王峰 科创： 科创计划部：姬延方、梁三鼎、郭一丁				

1、项目背景

2024 年 10 月，我中心通过《在线服务公司 2024-2025 年智算资源服务采购框架项目》采购了广东、浙江、内蒙古 3 个省公司的智算资源服务，目前已使用 824 张卡，7 月份智算资源利用率达到 49.36%，有效支撑了“灵犀”智能助理、客服大模型等“AI+”应用规模化推广。

由于该项目合同将于 2025 年底到期，为匹配中心“AI+”应用规模推广的智算供给需求，2025 年 5 月中心审议通过的《关于在线中心 2025-2026 年智算资源需求和选址的请示》（中心总办纪（2025）28 号），明确了中心智算节点选址范围及 2025 年四季度至 2026 年二季度智算资源需求规模（见附件 7），为后续智算资源供给提供了指导依据。其中，根据 2025 年 7 月集团公司对加大自主可控算力使用的指导精神，原计划立项的《2025 年低成本智算服务项目》（44 台智算主机共 352 张低成本 GPU 卡）无法继续执行采购，特申请将其既定预算 455.95 万元用于国产化推理型智算资源采购。

2、项目目标

本项目拟构建多节点、高可用的推理型智算供给能力，通过采购高性能推理卡（昇腾 910B4，下同）2105 张、低性能推理卡（昇腾 310P，下同）44 张，支撑 2025 年至 2026 年上半年中心客户端应用、服务端应用和云客服端应用等场景推广的算力需求。

3、项目内容

（1）“灵犀”智能助理智算资源量

当前“灵犀”当前使用高性能推理卡 80 张。据 AI 能力中心反馈，按照当前“灵犀”业务增速（以近 7 个月交互率为计算依据），预计新增 1100 万交互用户，需扩容高性能推理卡 156 张，需求总量为 236 张，另按 10%规模预留应急资源，高性能推理卡需求上限为 260 张。

（2）客服赋能场景智算资源量

当前客服赋能场景已使用高性能推理卡 261 张。据 AI 能力中心反馈，下阶段将推进智能工单、智能教练、坐席辅助、知识库等规模推广，以及分中心一线“AI+”众创，需新增高性能推理卡 771 张、低性能推理卡 40 张，需求总量为高性能推理卡 1032 张、低性能推理卡 40 张，另按 10%规模预留应急资源，高性能推理卡需求上限为 1135 张、低性能推理卡需求上限为 44 张。

（3）客服赋能场景智算资源量

当前客服赋能场景已使用高性能推理卡 261 张。据 AI 能力中心反馈，下阶段将推进智能工单、智能教练、坐席辅助、知识库等规模推广，以及分中心一线“AI+”众创，需新增高性能推理卡 771 张、低性能推理卡 40 张，需求总量为高性能推理卡 1032 张、低性能推理卡 40 张，另按 10%规模预留应急资源，高性能推理卡需求上限为 1135 张、低性能推理卡需求上限为 44 张。

（4）云客服智算资源量

当前云客服尚未使用中心智算资源，据云客服事业部（中移智捷）反馈，为支撑云客服产品大模型升级和实名认证深度鉴伪能力全网推广，需新增高性能推理卡 97 张，另按 10%规模预留应急资源，高性能推理卡需求上限为 107 张。

	(5) 云专线组网及配套资源 通过云专线组网，实现在线洛阳、淮安数据中心与智算节点机房（以 4 个智算节点进行测算）之间安全、高效互通，构建双中心链路容灾，稳定支撑智算资源跨地域统一纳管和调度。通过云主机、云硬盘和并行存储等资源，支撑智算节点（以 4 个智算节点进行测算）管理集群建设和模型文件存储。 4、项目预算情况 本项目整体预算上限为不含税 5632.1 万元（含税约为 5970.03 万元），其中，2025 年计划列支金额 756.18 万元，剩余 4875.92 万元计划于 2026 列支。属于成本类支出，项目归口管理单位为平台运维中心。由 AI 能力中心、云客服事业部等需求单位按需下单和结算，下单前须经科创计划部（数智化部）进行预算审核确认；由平台运维中心统筹负责资源发放支撑、运行监控等资源运营管理，推动智算资源合理、充分使用。 5、中台三问落实情况 (1) 和中台什么关系？ 落实集团关于 GPU 智算资源“集中训练、分布推理”管控要求，本项目拟租赁集团智算资源，支撑大模型应用快速上线和灵活拓展。 (2) 能不能复用中台能力？ 不涉及中台能力复用。 (3) 能不能沉淀中台能力？ 不涉及中台能力沉淀。	
评审纪要	各位评审专家对本项目的背景、目标、内容等方面进行评审，一致认为项目整体目标明确、需求合理，同意立项。评审专家主要提出以下意见，（1）建议立项请示补充历史项目对比情况。（2）建议明确项目 2025 年计划列支金额。（3）灵犀交互用户数 2026 年预计达到 7000 万，建议加强灵犀智算资源保障，提升支撑及时性。（4）建议明确项目合同主体。	
评审结果	战规技评审意见	项目在 IT 架构中归属技术与管理支撑域基础资源平台，命名符合规范，战略上为持续平稳投入的领域，符合公司整体战略规划，属于成本类计划内项目。原则上同意立项。原则上同意立项。
	业务评审意见	项目背景描述符合实际，项目需求有效，项目内容解释合理，且项目目标可以有力支撑业务目标的实现。原则上同意立项。
	技术评审意见	项目提供的材料合规完整，项目建设方案技术上可行，投资内容测算合理。原则上同意立项。
	中台三问	项目租赁集团智算资源，不涉及中台能力服用和能力沉淀。

	评审意见							
	安全评审意见		项目符合安全管理规范要求，原则上同意立项。					
	财务评审意见		项目符合财务管理要求，原则上同意立项。					
专家签字	规技 评审	郭旭方 梁玉鼎 郭丁	业务 评审	张士新 鲍子林 孟祥义	朱亚辉 吴洋洋 史津丞	技术 评审	白子玉 周洋	李超峰 王家辉
	中台 三问 评审	王山峰	安全 评审	张荣勋 刘光旭 张明	财务 评审	毛以琦		
资金类型	○研发资本化 ○研发成本化 ●成本类 ○投资类 ○零购 ○其他							
项目预算	5632.1 万元 ○含税 ●不含税							
组织方 签字	梁玉鼎		预算管理 签字		郭丁			